


Regresión Lineal

Vamos a partir de un conjunto de datos que corresponden a un problema clásico: precio de vivienda en función de la superficie

X	Y
m ²	€
60	210K
70	230K
70	215K
75	225K
80	240K
90	280K



Notación

x^j = variable de entrada / atributo / característica

y^j = variable de salida / valor real / ground truth

$\hat{y}^j$ = predicción

$a, b \rightarrow \theta_1, \theta_0 \Rightarrow \hat{y}^j = h_{\theta}(x^j) = \theta_0 + \theta_1 x^j$

Matricialmente

$$X = \begin{pmatrix} x_1^1 & x_1^2 & \dots & x_1^m \\ x_2^1 & x_2^2 & \dots & x_2^m \\ \vdots & \vdots & \ddots & \vdots \\ x_m^1 & x_m^2 & \dots & x_m^m \end{pmatrix} \quad Y = \begin{pmatrix} y^1 \\ y^2 \\ \vdots \\ y^m \end{pmatrix} \quad \hat{Y} = \begin{pmatrix} \hat{y}^1 \\ \hat{y}^2 \\ \vdots \\ \hat{y}^m \end{pmatrix} = \begin{pmatrix} 1 & x^1 \\ 1 & x^2 \\ \vdots & \vdots \\ 1 & x^m \end{pmatrix} \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix} = X \theta$$

$$\Downarrow$$

$$X = \begin{pmatrix} 1 & x_1^1 & x_1^2 & \dots & x_1^m \\ 1 & x_2^1 & x_2^2 & \dots & x_2^m \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_m^1 & x_m^2 & \dots & x_m^m \end{pmatrix}$$

Definamos el error: Dado $x^j, y^j, j=1, \dots, m$

$$J(\theta) = \frac{1}{m} \sum_{j=1}^m |\hat{y}^j - y^j| \quad \text{Error absoluto medio} \quad \text{M.A.E.}$$

Problema 1.1 No derivable

$$J(\theta) = \frac{1}{m} \sum_{j=1}^m (\hat{y}^j - y^j)^2 = \frac{1}{m} \sum_{j=1}^m (\theta_0 + \theta_1 x^j - y^j)^2 \quad \text{M.S.E.}$$

↳ Infinitamente derivable C^∞ ; Lipschitz; convexa

Objetivo: Dados $\{x^j, y^j\}_{j=1, \dots, m}$ encontrar $\theta = \{\theta_0, \theta_1\}$ tal que se minimice el MSE $\equiv \arg\min_{\theta} J(\theta)$

Aproximación Cálculo

Problema mínimos $\Leftrightarrow \nabla J(\theta) = 0$ Def. Pto crítico

$J(\theta) > 0$ convexa $\Rightarrow J'$ mínimo global

$$J(\theta) = J(\theta_0, \theta_1) = \frac{1}{m} \sum_{j=1}^m (\theta_0 + \theta_1 x^j - y^j)^2$$

$$\nabla J = 0 \Rightarrow \begin{cases} \frac{\partial}{\partial \theta_0}: \frac{1}{m} \sum_{j=1}^m 2(\theta_0 + \theta_1 x^j - y^j) \cdot 1 = 0 \\ \frac{\partial}{\partial \theta_1}: \frac{1}{m} \sum_{j=1}^m 2(\theta_0 + \theta_1 x^j - y^j) x^j = 0 \end{cases} \Rightarrow$$

$$\begin{cases} \sum_{j=1}^m (\theta_0 + \theta_1 x^j - y^j) = 0 & \Rightarrow \sum_{j=1}^m \theta_0 + \sum_{j=1}^m \theta_1 x^j - \sum_{j=1}^m y^j = 0 \\ \sum_{j=1}^m (\theta_0 + \theta_1 x^j - y^j) x^j = 0 & \Rightarrow \sum_{j=1}^m \theta_0 x^j + \sum_{j=1}^m \theta_1 x^j x^j - \sum_{j=1}^m y^j x^j = 0 \end{cases}$$

$$\Rightarrow \begin{cases} \theta_0 \sum_{j=1}^m 1 + \theta_1 \sum_{j=1}^m x^j = \sum_{j=1}^m y^j \\ \theta_0 \sum_{j=1}^m x^j + \theta_1 \sum_{j=1}^m x^j x^j = \sum_{j=1}^m x^j y^j \end{cases} \Rightarrow \begin{pmatrix} \sum_{j=1}^m 1 & \sum_{j=1}^m x^j \\ \sum_{j=1}^m x^j & \sum_{j=1}^m x^j x^j \end{pmatrix} \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix} = \begin{pmatrix} \sum_{j=1}^m y^j \\ \sum_{j=1}^m x^j y^j \end{pmatrix}$$

Ecuación normal

$$X^T X \theta = X^T Y$$

Matricialmente:

$$X = \begin{pmatrix} 1 & x^1 \\ 1 & x^2 \\ \vdots & \vdots \\ 1 & x^m \end{pmatrix} \Rightarrow X^T X = \begin{pmatrix} 1 & 1 & \dots & 1 \\ x^1 & x^2 & \dots & x^m \end{pmatrix} \begin{pmatrix} 1 & x^1 \\ 1 & x^2 \\ \vdots & \vdots \\ 1 & x^m \end{pmatrix} = \begin{pmatrix} \sum 1 & \sum x^j \\ \sum x^j & \sum x^j x^j \end{pmatrix}$$


$$X^T Y = \begin{pmatrix} 1 & 1 & \dots & 1 \\ x^1 & x^2 & \dots & x^m \end{pmatrix} \begin{pmatrix} y^1 \\ \vdots \\ y^m \end{pmatrix} = \begin{pmatrix} \sum y^j \\ \sum x^j y^j \end{pmatrix}$$

Aproximación Álgebra Lineal

$$X\theta = \hat{Y} \approx Y$$

$$\hookrightarrow \begin{pmatrix} x_1' \\ x_2' \\ \vdots \\ x_m' \end{pmatrix} \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix} = \underbrace{\theta_0 \vec{V}_0 + \theta_1 \vec{V}_1}_{\{ \vec{V}_0, \vec{V}_1 \}}$$

Subespacio generado por $\{ \vec{V}_0, \vec{V}_1 \} = H$



¿Qué vector $\hat{Y} \in H$ tiene distancia mínima respecto a Y ?

El vector de H que minimiza $Y - \hat{Y}$ es la proyección ortogonal de Y en H

$\hat{Y} = Y_{\perp H} \Rightarrow$ ¿Que valores de $\theta = (\theta_0, \theta_1)$ corresponden a $Y_{\perp H}$?

$$\text{Defino } E = \hat{Y} - Y \Rightarrow E \perp H \Rightarrow \begin{cases} E \perp \vec{V}_0 \\ E \perp \vec{V}_1 \end{cases} \Rightarrow \begin{cases} (\hat{Y} - Y) \cdot \vec{V}_0 = 0 \\ (\hat{Y} - Y) \cdot \vec{V}_1 = 0 \end{cases}$$

$$\begin{cases} \vec{V}_0 \cdot (X\theta - Y) = 0 \\ \vec{V}_1 \cdot (X\theta - Y) = 0 \end{cases} \Rightarrow \begin{pmatrix} \vec{V}_0 \cdots \\ \vec{V}_1 \cdots \end{pmatrix} (X\theta - Y) = 0$$

$$\Rightarrow X^T (X\theta - Y) = 0 \Rightarrow$$

Ecuación normal

$$X^T X \theta = X^T Y$$

Caso multivariable

$$\{x^j, y\}_{j=1 \dots m} \rightarrow x^j = \{x_1^j, x_2^j, \dots, x_n^j\}$$

m^2 # hab, ..., # atributos

Predicción $\hat{y}^j = \theta_0 + \theta_1 x_1^j + \theta_2 x_2^j + \dots + \theta_n x_n^j = \sum_{i=0}^n \theta_i x_i^j$ con $x_0^j = 1$

Matricialmente atributos/características

$$X = \begin{pmatrix} 1 & x_1^1 & x_2^1 & \dots & x_n^1 \\ 1 & x_1^2 & x_2^2 & \dots & x_n^2 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^m & x_2^m & \dots & x_n^m \end{pmatrix} \in M_{m \times (n+1)} \quad \hat{y} \in M_{m \times 1} \quad y \in M_{m \times 1}$$

$\theta \in M_{(n+1) \times 1}$

muestras

$\hat{y} = X\theta \approx y$ Buscamos $\theta = [\theta_0, \theta_1, \dots, \theta_n]^T$ que minimice el error dado $\{x^j, y^j\}$

$$\text{Error} = \frac{1}{m} \sum_{j=1}^m (h_\theta(x^j) - y^j)^2 = \frac{1}{m} \sum_{j=1}^m \left(\sum_{i=0}^n \theta_i x_i^j - y^j \right)^2 = J(\theta)$$

Si definimos $X\theta - y = \begin{pmatrix} \sum_{i=0}^n \theta_i x_i^1 - y^1 \\ \sum_{i=0}^n \theta_i x_i^2 - y^2 \\ \vdots \\ \sum_{i=0}^n \theta_i x_i^m - y^m \end{pmatrix}$ m muestras

$$J(\theta) = \frac{1}{m} (X\theta - y)^T (X\theta - y) \quad \Gamma v^T v = \sum_{i=0}^n v_i^2$$

Opción 1] $\nabla J(\theta) = 0$ Requiere conceptos avanzados de cálculo matricial

Opción 2]

$$X = \begin{pmatrix} 1 & x_1^1 & x_2^1 & \dots & x_n^1 \\ 1 & x_1^2 & x_2^2 & \dots & x_n^2 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^m & x_2^m & \dots & x_n^m \end{pmatrix} \quad \pi = \{(\lambda v_0, v_1, \dots, v_n)\} \Rightarrow \hat{y} - y \perp \vec{v}_i \quad \forall i$$

$y \notin \pi \quad \hat{y} = y \perp \pi$

$\Rightarrow X^T X \theta = X^T y$ Ec. normal


La ecuación normal es fantástica. Nos permite calcular los coeficientes de la aproximación lineal resolviendo un sistema lineal $Ax=b$ donde A y b solo dependen de los datos de entrada. Pero:

- $X^T X \equiv A$ puede ser casi-singular si los datos están muy próximos. Los métodos iterativos de solución dependen del condicionamiento de A
- Incluso sin ser singular $\Theta = (X^T X)^{-1} (X^T y)$ Muy costoso

~~Método Directo
LU~~

Método Iterativo
- Jacobi - Gauss-Seidel
✓ - Descenso de Gradiente

Método del descenso de gradiente



Método iterativo para buscar x tq $f'(x)=0$

x^0 Empezamos con un valor aproximado


$$x^1 = x^0 - \alpha f'(x^0)$$

$$x^2 = x^1 - \alpha f'(x^1)$$

$$x^i = x^{i-1} - \alpha f'(x^{i-1})$$


α tasa de aprendizaje

Limitaciones del método



mínimo local

Valor de α puede alejarme de un mínimo local



$J(\theta) \in C^0 + \text{Lipschitz} + \text{Convexa} \Rightarrow \exists!$ mínimo global

Implementación

$$\Theta^{(k+1)} = \Theta^k - \alpha \nabla J(\Theta^k) \quad \alpha = \text{tasa de aprendizaje}$$

Caso multivariable

$$\begin{pmatrix} \Theta_0 \\ \Theta_1 \\ \vdots \\ \Theta_n \end{pmatrix}^{(k+1)} = \begin{pmatrix} \Theta_0 \\ \Theta_1 \\ \vdots \\ \Theta_n \end{pmatrix}^k - \alpha \begin{pmatrix} \frac{\partial}{\partial \Theta_0} J(\Theta^k) \\ \frac{\partial}{\partial \Theta_1} J(\Theta^k) \\ \vdots \\ \frac{\partial}{\partial \Theta_n} J(\Theta^k) \end{pmatrix}$$

Veamos cómo se comporta

$$\frac{\partial}{\partial \Theta_i} J(\Theta^k) = \frac{\partial}{\partial \Theta_i} \left(\frac{1}{m} \sum_{j=1}^m (h_{\Theta}(x^j) - y^j)^2 \right) = \frac{1}{m} \sum_{j=1}^m 2(h_{\Theta}(x^j) - y^j) x_i^j$$

$$\nabla J(\Theta^k) = \frac{2}{m} \begin{pmatrix} \sum_{j=1}^m (h_{\Theta}(x^j) - y^j) x_0^j \\ \sum_{j=1}^m (h_{\Theta}(x^j) - y^j) x_1^j \\ \vdots \\ \sum_{j=1}^m (h_{\Theta}(x^j) - y^j) x_n^j \end{pmatrix} \quad \text{X}\Theta - \gamma$$

Matricialmente

$$X^T (X\Theta - \gamma)$$
$$\begin{bmatrix} (n+1) \times m \\ m \times 1 \end{bmatrix} \times \begin{bmatrix} m \times 1 \end{bmatrix} = \begin{bmatrix} (n+1) \times 1 \end{bmatrix}$$
$$\begin{pmatrix} 1 & \dots & 1 \\ x_1^1 & x_1^2 & \dots & x_1^m \\ \vdots & \vdots & \ddots & \vdots \\ x_n^1 & x_n^2 & \dots & x_n^m \end{pmatrix} \begin{pmatrix} h_{\Theta}(x^1) - y^1 \\ h_{\Theta}(x^2) - y^2 \\ \vdots \\ h_{\Theta}(x^m) - y^m \end{pmatrix}$$

$$\Rightarrow \nabla J(\Theta^k) = \frac{2}{m} X^T (X\Theta - \gamma)$$

$\Rightarrow$ Descenso de gradiente


$$\Theta^{(k+1)} = \Theta^k - \alpha \frac{2}{m} X^T (X\Theta^k - \gamma)$$

Problema: muy costoso en cada paso (época). Iterar sobre todo el conjunto

$\rightarrow$ Solución:

- Batch-learning: Iterar sobre todo el conjunto
- Mini-batch-learning: En cada epoch se usa un subconjunto aleatorio
- Stochastic GD: En cada epoch se itera sobre un subconjunto aleatorio (actualizando). En el caso más agresivo en cada epoch se usa un solo elemento

Regresión Polinómica



$$\hat{y} = \theta_0 + \theta_1 x$$

$$\hat{y} = \theta_0 + \theta_1 x + \theta_2 x^2$$

$$\hat{y} = \theta_0 + \theta_1 x + \theta_2 x^2 + \dots + \theta_k x^k$$

Está claro que la regresión lineal (grados 1) no es suficiente para explicar la complejidad de los datos. Por otro lado un orden polinómico muy alto puede ajustarse en exceso a los datos disponibles pero perder la capacidad de generalizar.

En cualquier caso podemos ver este problema como un caso de regresión múltiple con un cambio de variable.

Definimos

$$\hat{y} = h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \dots + \theta_n x^n = \sum_{i=0}^n \theta_i x^i$$

Hacemos el cambio de variable

$$\begin{cases} z_0 = x^0 = 1 \\ z_1 = x^1 \\ \vdots \\ z_n = x^n \end{cases} \Rightarrow \hat{y} = h_{\theta}(z) = \theta_0 + \theta_1 z_1 + \theta_2 z_2 + \dots + \theta_n z_n$$

Extender este problema al caso multivariable polinómico es trivial

$$\begin{aligned} h_{\theta}(x, y) &= \theta_0 + \theta_1 x + \theta_2 y + \theta_3 x^2 + \theta_4 xy + \theta_5 y^2 + \dots \\ &= \theta_0 + \theta_1 z_1 + \theta_2 z_2 + \theta_3 z_3 + \theta_4 z_4 + \theta_5 z_5 + \dots \end{aligned}$$

Volviendo al ejemplo inicial

$$\hat{y} = \theta_0 + \theta_1 x$$

Underfitting

Mala aproximación, el orden bajo no captura el comportamiento no lineal. No describe los datos conocidos y probablemente no hará buenas predicciones. High bias = Alto sesgo

$$\hat{y} = \sum_{i=0}^K \theta_i x^i$$

Overfitting

Mala aproximación, orden demasiado alto se ajusta demasiado a los datos conocidos y pierde la capacidad de generalizar

High variance = Alta varianza

$\hat{y} = \theta_0 + \theta_1 x + \theta_2 x^2$ Buena aprox. Compromiso entre describir lo

conocido sin perder capacidad de generalizar

Bias-Variance Trade off

¿Existe alguna forma de encontrar el orden adecuado sin probarlos?

Regularización

Idea: Definir una función de pérdida que penalice tanto el error cometido en los datos conocidos como usar variables de entrada innecesarias en la predicción

$$J(\theta) = \frac{1}{m} \sum_{j=1}^m (h_{\theta}(x^{(j)}) - y^{(j)})^2 + \lambda \sum_{i=1}^n \theta_i^2$$

Para minimizar $J(\theta)$ forzamos a que $\theta_i \ll 1$ si las variables asociadas no son importantes en la predicción

Tipos

Ridge: $J(\theta) = \frac{1}{m} \sum_{j=1}^m (h_{\theta}(x^{(j)}) - y^{(j)})^2 + \lambda \sum_{i=1}^n \theta_i^2$

Lasso: $J(\theta) = \frac{1}{m} \left[\right] + \lambda \sum_{i=1}^n |\theta_i|$

Elastic-net: $J(\theta) = \frac{1}{m} \left[\right] + \lambda_1 \sum_{i=1}^n \theta_i^2 + \lambda_2 \sum_{i=1}^n |\theta_i|$

Comentarios

- No se regulariza Θ_0 . No está asociado a ninguna variable
- $\lambda > 0$. Pero cuidado $\lambda \ll 1 \Rightarrow$ No regulariza
 $\lambda \gg 1 \Rightarrow h_\Theta(x) = \Theta_0$
- Ridge $\Rightarrow \Theta_i \ll 1 \Rightarrow$ Preferible con muchas variables relacionadas
Lasso $\Rightarrow \Theta_i = 0 \Rightarrow$ Preferible con variable irrelevante
(pocos datos y muchas variables)
Lasso aumenta la interpretabilidad (elimina variables)
- Ridge es + estable: los coeficientes cambian menos si los datos cambian poco (diferenciado)
- Para regularizar es necesario estandarizar las variables
(Idem $X^T X$ matriz de covarianzas. Requiere varianzas $\approx$)

Implementación (Ridge)

$$J(\Theta) = \frac{1}{m} \sum_{j=1}^m (h_\Theta(x^j) - y^j) + \lambda \sum_{i=1}^n \Theta_i^2$$

$$\nabla J(\Theta) = 0$$

$$i=0 \quad \frac{\partial}{\partial \Theta_0} = \frac{2}{m} \sum_{j=1}^m (h_\Theta(x^j) - y^j) = 0$$

$$i \neq 0 \quad \frac{\partial}{\partial \Theta_i} = \frac{2}{m} \sum_{j=1}^m (h_\Theta(x^j) - y^j) x_i^j + 2\lambda \Theta_i = 0$$

$\Rightarrow$ Ecuación normal + regularización

$$(X^T X + \lambda D) \Theta = X^T Y \quad \text{con } D =$$

con regularización $A = (X^T X + \lambda D)$
es más diagonal dominante

$$\xrightarrow{n+1} D = \begin{pmatrix} 0 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & 0 & 1 \end{pmatrix}$$

Descenso de Gradiente + Regularización

$$\Theta^{k+1} = \Theta^k - \alpha \nabla J(\Theta^k)$$

$$\text{Para } \Theta_0 = \Theta_0^{k+1} = \Theta_0^k - \alpha \frac{2}{m} \left(\sum_{j=1}^m (h_{\Theta^k}(x^j) - y^j) \right)$$

$$\Theta_i = \Theta_i^{k+1} = \Theta_i^k - \alpha \left(\frac{2}{m} \sum_{j=1}^m (h_{\Theta^k}(x^j) - y^j) x_i^j + 2\lambda \Theta_i^k \right)$$

$$\Rightarrow \Theta_i^{k+1} = (1 - 2\alpha\lambda) \Theta_i^k - \alpha \frac{2}{m} \left(\sum_{j=1}^m (h_{\Theta^k}(x^j) - y^j) x_i^j \right)$$

Matricialmente

$$\Theta^{k+1} = D \Theta^k - \alpha (X^T (X \Theta^k - Y))$$

$$D = \left(\begin{array}{c|cccc} 1 & 0 & \dots & \dots & 0 \\ 0 & 1-2\alpha\lambda & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & 0 & 1-2\alpha\lambda \end{array} \right)$$

ESTANDARIZACIÓN EN DESCENSO DE GRADIENTE

En regresión lineal usando MSE se puede ver que

$$\nabla^2 J(\theta) = \frac{2}{m} X^T X$$

La velocidad de convergencia del método de descenso de gradiente depende del número de condición

$$k = \frac{\lambda_{\max}}{\lambda_{\min}}$$

Si la matriz de datos X tiene variables con escalas muy diferentes $X^T X$ estará mal condicionada. Eso se traduce además en que la función de coste tiene curvas de nivel en forma de elipsoides alargados lo que implica que el descenso de gradiente se ralentiza por el zigzagado del gradiente

Una posible solución para por estandarizar los atributos de entrada

$$X^* = \frac{X - \mu}{\sigma} \quad \text{con } X = \{x_1, x_2, x_3, \dots, x_n\}$$

* $x_0 = 1$ no se estandariza

Ahora aplicamos descenso de gradiente para buscar los coeficientes en las variables estandarizadas que minimizan la función de error

$$X^* \xrightarrow{\text{GD}} \theta^*$$

$$\hat{y} = \theta_0^* + \sum_{i=1}^n \theta_i^* x_i^*$$

Deshacemos el cambio

$$\hat{y} = \theta_0^* + \sum_{i=1}^n \theta_i^* \frac{x_i - \mu_i}{\sigma_i} = \theta_0^* + \sum_{i=1}^n \frac{-\theta_i^* \mu_i}{\sigma_i} + \sum_{i=1}^n \theta_i^* \frac{x_i}{\sigma_i}$$

$$\Rightarrow \hat{y} = \theta_0 + \sum_{i=1}^n \theta_i x_i \quad \text{siendo} \quad \left| \begin{array}{l} \theta_0 = \theta_0^* - \sum_{i=1}^n \theta_i^* \frac{\mu_i}{\sigma_i} \\ \theta_i = \frac{\theta_i^*}{\sigma_i} \end{array} \right.$$